

Bygge statistiske modeller med kategoriske prediktorvariabler (ANOVA, t-test)

Christian Magelssen og Knut Sindre Mølmen

2021-05-02

Contents

| | | |
|----------|--|-----------|
| 1 | Introduksjon | 5 |
| 1.1 | Om denne boken | 6 |
| 2 | Datasett | 7 |
| 2.1 | Bør man trene med ett eller flere sett i styrketrening? | 7 |
| 2.2 | Gjennomsnitt for de to gruppene | 8 |
| 2.3 | Figur av datasettet | 10 |
| 3 | Koding av kategoriske prediktorvariabler | 13 |
| 3.1 | Dummykoding | 13 |
| 4 | Bygge statistisk modeller | 15 |
| 4.1 | Introduksjon til modellbygging | 15 |
| 4.2 | Visualisering av ulike statistiske modeller | 17 |
| 4.3 | Modellbygging med ‘Null-Hypothesis Significance Testing (NHST)’ | 20 |
| 5 | Sammenligne modeller | 31 |
| 5.1 | ANOVA-tabell (variansanalyse) | 32 |
| 5.2 | Teste (statistisk) om vår alternative modell forklarer mer varians enn null-modellen | 34 |
| 6 | Hvordan finne linjen i modellen? | 39 |
| 7 | T-test - er b_1 signifikant forskjellig fra null? | 43 |
| 8 | Skrive en t-test | 47 |

| | | |
|-----------|--|-----------|
| 9 | Sammenligne flere grupper | 49 |
| 9.1 | Datasett | 49 |
| 9.2 | Oppsummere og visualisere dataen | 50 |
| 9.3 | Dummykoding | 50 |
| 9.4 | ANOVA - er modellen vår bedre enn null-modellen? | 52 |
| 9.5 | Hvilke grupper er forskjellige? (post-hoc testing) | 54 |
| 10 | Regresjon og korrelasjon | 57 |
| 10.1 | Datasett | 58 |
| 10.2 | Visualisering av dataen | 58 |
| 10.3 | Pearson's korrelasjonskoeffisient (r) | 58 |
| 10.4 | Regresjon | 62 |
| 10.5 | Rapportering av regresjon | 64 |
| 11 | VEDLEGG | 65 |
| 11.1 | Datasett | 65 |
| 11.2 | Modellbygging | 65 |
| 11.3 | Sammenligne modeller | 66 |

Chapter 1

Introduksjon

I dette kapittelet skal vi lære å bygge statistiske modeller for å **undersøke om en avhengig, kontinuerlig variabel** (eks. det maksimale oksygenopptaket) er statistisk forskjellig mellom to (eks. kvinner og menn) eller flere grupper (eks. maratonløpere, skiløpere, kulestøtere og inaktive).

En variabel kan sies å være **kontinuerlig** når vi kan bestemme hvor presist vi ønsker å måle den. For eksempel regnes tid som en kontinuerlig variabel fordi det (i prinsippet) ikke finnes noen grenser hvor presist vi kan måle tid; vi kan måle det i år, måneder, uker, dager, timer, minutter, sekunder, tideler, hundredeler eller tusendeler.

Grupper defineres i psykologifaget som en samling mennesker som deler bestemte karakteristikk. Det kan være spillere på et fotballag, individer på et treningssenter, eller menn og kvinner. Dette er også eksempler på naturlig inndelte grupper i samfunnet. Noen ganger kan det være interessant å se om disse gruppene er forskjellige. For eksempel kan det være interessant å se om individer som trener på treningssenter er sterkere enn de som ikke trener på treningssenter.

Andre ganger kan det være interessant å teste om to grupper, som var like før et eksperiment, har blitt forskjellige fordi vi har behandlet dem ulikt. Vi randomiserer individer i to ulike grupper, slik at vi sikrer at vi blander disse individene godt (f.eks kjønn, motivasjon, interesser). Hvis eksperimentet har blitt gjennomført godt, dvs. at det ikke er noen andre forklaringer på at disse to gruppene har blitt forskjellige etter intervensjonsperioden, så kan vi trekke en slutning om at disse to gruppene trolig ikke kommer fra samme populasjon lenger; altså at gruppene har blitt ulike.

1.1 Om denne boken

Dette er en interaktiv bok, skrevet i R. Boken består av tekst, videoer, og oppgaver. Vi anbefaler på det sterkeste at du løser oppgavene. Boksen lyser grønt om du har riktig svar, og rødt når du svaret er galt eller ikke fylt inn. Du kan også sjekke med fasiten som ligger bakerst i boken. Om du oppdager feil, vennligst si fra.

Lykke til!

Chapter 2

Dataseett

2.1 Bør man trene med ett eller flere sett i styrketrening?

Mange utrente lurer på hvor mange serier de bør gjennomføre for å oppnå maksimal treningseffekt i styrketrening. Noen føler at de blir slitne etter ett sett og at dette derfor er tilstrekkelig. Andre mener at et større treningstimuli er nødvendig, selv om man er utrent, og at to eller flere sett derfor er bedre. En forsker som var tidlig ute med å undersøke dette var Bent Rønnestad (Rønnestad et al., 2007)

Eksperimentet ble gjennomført som et **between-subject design** med to grupper: * en gruppe trente 1 sett på underkroppen og 3 sett på overkroppen * en annen gruppe trente 3 sett på underkroppen og 1 sett på overkroppen.

Disse gruppene kalte han henholdsvis **1L-3U** og **3L-1U** (L=lower; U=Upper).

De to gruppene trente 3 økter i uken i totalt 11 uker. Forskergruppen ville så se hva som ga mest fremgang i 1 repetisjon maksimum (1RM) på underkroppsovelser. Den avhengige variabelen ble derfor %-fremgang på 1RM på underkroppsovelser.



Vi har ikke tilgang til dette datasettet, men vi har simulert dette datasettet i R basert på verdiene som ble oppgitt i artikkelen. Datasettet blir tilnærmet likt, men siden det er en simulering blir det aldri helt identisk. Datasettet ser du i tabellen under.

Du kan få nøyaktig samme datasett ved å klippe ut og lime inn følgende kode i en skript-fil i R (husk å laste inn tidyverse-pakken, `library(tidyverse)`). Du kan også laste ned datasettet som en .csv fil fra canvas.

```
set.seed(2002) #viktig å ha med denne for å få nøyaktig samme datasett
tre.sett <- round(rnorm(n = 12, mean = 41, sd = 5), 2) #12 individer
ett.sett <- round(rnorm(n = 12, mean = 21, sd = 5), 2) #12 individer
```

```
#lager en tibble fra tidyverse-pakken. Må ha lastet inn tidyverse library(tidyverse) i
dat <- tibble(individ = seq(1:24),
              gruppe = rep(c("tre.sett", "ett.sett"), c(length(tre.sett), length(ett.sett))),
              rm = c(tre.sett, ett.sett))
```

Oppgave

Før du går videre er det greit at du gjør deg kjent med datasettet som vi har generert. Studer datasettet og svar på følgende spørsmål:

- Hvor mange kolonner er det i tabellen over?
- Hvor mange deltakere var med i studien?
- Hvilke to verdier har variabelen 'gruppe'? og

2.2 Gjennomsnitt for de to gruppene

Bra! Det er alltid viktig å bli kjent med sitt eget datasett, men nå som du har det kan vi gå videre. Vi er interessert i om det er forskjeller i prosentvis styrkefremgang fra pre- til posttest mellom de to gruppene ("tre.sett" vs. ett.sett). Vi kan starte med å se om det er forskjeller i gjennomsnitt mellom to gruppene.

Table 2.1: Simulert datasett

| individ | gruppe | rm |
|---------|----------|----------|
| 1 | tre.sett | 40.46704 |
| 2 | tre.sett | 49.07223 |
| 3 | tre.sett | 47.94131 |
| 4 | tre.sett | 44.51389 |
| 5 | tre.sett | 52.28750 |
| 6 | tre.sett | 40.01750 |
| 7 | tre.sett | 49.48425 |
| 8 | tre.sett | 29.21048 |
| 9 | tre.sett | 40.59293 |
| 10 | tre.sett | 37.58676 |
| 11 | tre.sett | 35.42651 |
| 12 | tre.sett | 42.49354 |
| 13 | ett.sett | 17.70576 |
| 14 | ett.sett | 17.07181 |
| 15 | ett.sett | 18.26811 |
| 16 | ett.sett | 25.42594 |
| 17 | ett.sett | 32.70313 |
| 18 | ett.sett | 19.10226 |
| 19 | ett.sett | 22.23827 |
| 20 | ett.sett | 22.27148 |
| 21 | ett.sett | 26.17889 |
| 22 | ett.sett | 20.34857 |
| 23 | ett.sett | 23.52773 |
| 24 | ett.sett | 17.95966 |

Dette kan enkelt gjøres i R, Jamovi eller excel. Her er en kode for å løse dette i R:

```
#jeg lager et oobjekt som heter mean_rm
mean_rm <- dat %>%
  #Jeg grupperer etter gruppe, slik at jeg får et mean for hver gruppe istf. for å få
  #group_by er en funksjon for dette
  group_by(gruppe) %>%
  #deretter bruker jeg summarise funksjonen for å regne gjennomsnitt
  summarise(mean.fremgang.1RM = mean(rm))
```

Koden gir oss følgende tabell: \begin{table}

\caption{Gjennomsnittlige %-vis fremgang for de to gruppene}

| gruppe | mean.fremgang.1RM |
|----------|-------------------|
| ett.sett | 21.90083 |
| tre.sett | 42.42417 |

\end{table}

Oppgave

d) Hvilken gruppe hadde mest fremgang? ett.sett tre.sett

2.3 Figur av datasettet

Vi kan også presentere dataen i en figur. For denne typen data er det veldig vanlig å bruke et **stolpediagram**:




Figure 2.1: Modeller med forskjellig b1

Et stolpediagram er pent å se på, men er egentlig designet for å kategoriske data. For eksempel er det fint å bruke dette når vi skal presentere frekvensen antall som har kjørt bil til skolen og antall personer som har gått. Les (Weissgerber et al., 2015)(<https://journals.plos.org/plosbiology/article?id=10.1371/journal.pbio.1002128>). Deretter svar på følgende spørsmål for å se om du har forstått problemene ved å bruke stolpediagram på kontinuerlig data.

Oppgave

- b. Hva får du hvis du summerer all erroren for alle indidene? null 0 3 -3.
- c. Stolpediagram er designet for kontinuerlig kategorisk data.
- d. Høyden på stolpen representerer (bruk det norske begrepet!), hvilket vil si at det også må ligge noen observasjoner over og under stolpen.
- e. Et stolpediagram viser ikke standard error standardavvik CI fordelingen av observasjonene, og dette spesielt være problematisk ved store små.
- f. Forfatterne av artikkelen anbefaler mer bruk av bar graph scatterplot for kontinuerlige variabler.
- g. Er standard error og standardavvik det samme? ja nei.

Chapter 3

Koding av kategoriske prediktorvariabler

I tabellen på forrige kan du se at vi har en tabell med tre kolonner: en kolonne for hver variabel vi har i vårt datasett.

- Variabelen `gruppe` er en kategorisk variabel som har to ulike verdier: “ett.sett” og “tre.sett.” Dette er de to gruppene som vi skal teste om er forskjellige fra hverandre. I programmeringsverdenen kalles dette for et «tekstobjekt», en «string» eller «character». Uansett navn er problemet at vi ikke kan legge ord inn i en statistisk modell. Vi er nødt til å omkode den kategoriske variabelen med tallverdier. Det er flere måter å gjøre dette på, og måten man gjør det på har stor betydning for utfallet av den statistiske analysen.

De forskjellige måtene å kode kategoriske prediktorvariabler gir forskjellige resultater. En veldig vanlig måte å gjøre dette på er å bruke dummykoding. Dette kan fungere godt når du bygger enkle statistiske modeller, slik vi skal gjøre nå. Imidlertid, dummykoding fungerer dårlig hvis du har mange grupper du ønsker å sammenligne, og du ikke ønsker å sammenligne disse gruppene mot en baseline/kontroll-gruppe. Da vil kontrastkoding være bedre egnet.

SPSS, R, Jamovi bruker dummykoding som standard, og det er viktig å ha i bakhodet når du tolker resultatene fra modellene.

3.1 Dummykoding

Den vanligste metoden kalles **dummykoding** eller treatment-koding. Den går ut på å lage en eller flere variabler med 0 og 1 som de to mulige verdiene.

Table 3.1: Dummykodet datasett

| individ | gruppe | rm | dummykodet |
|---------|----------|----------|------------|
| 1 | tre.sett | 40.46704 | 1 |
| 2 | tre.sett | 49.07223 | 1 |
| 3 | tre.sett | 47.94131 | 1 |
| 4 | tre.sett | 44.51389 | 1 |
| 5 | tre.sett | 52.28750 | 1 |
| 6 | tre.sett | 40.01750 | 1 |
| 7 | tre.sett | 49.48425 | 1 |
| 8 | tre.sett | 29.21048 | 1 |
| 9 | tre.sett | 40.59293 | 1 |
| 10 | tre.sett | 37.58676 | 1 |
| 11 | tre.sett | 35.42651 | 1 |
| 12 | tre.sett | 42.49354 | 1 |
| 13 | ett.sett | 17.70576 | 0 |
| 14 | ett.sett | 17.07181 | 0 |
| 15 | ett.sett | 18.26811 | 0 |
| 16 | ett.sett | 25.42594 | 0 |
| 17 | ett.sett | 32.70313 | 0 |
| 18 | ett.sett | 19.10226 | 0 |
| 19 | ett.sett | 22.23827 | 0 |
| 20 | ett.sett | 22.27148 | 0 |
| 21 | ett.sett | 26.17889 | 0 |
| 22 | ett.sett | 20.34857 | 0 |
| 23 | ett.sett | 23.52773 | 0 |
| 24 | ett.sett | 17.95966 | 0 |

Antall variabler vi trenger avhenger av antall grupper vi vil sammenligne. Siden vårt datasett kun inneholder to grupper, så trenger vi kun en variabel. Vi kan kalle den ene gruppen «0» og den andre «1». Hovedregelen er at vi gir 0 til baseline/kontroll-gruppen og 1 til den eksperimentelle gruppen. Vi gir derfor 0 til 1.sett-gruppen og 1 til 3.sett-gruppen. Gjør dette før du går videre.

I R og Jamovi kan du gjøre det med følgende if/else statement. I R kan du bruke følgende kode:

```
#lager et nytt objekt som heter dummykodet.dat
dummykodet.dat <- dat %>%
  # her lager jeg en ny kolonne som heter dummykoder. If gruppe == 'ett.sett', gi verd
  mutate(dummykodet = if_else(gruppe == "ett.sett", 0, 1))
```

I jamovi ville jeg sett følgende video:

Chapter 4

Bygge statistisk modeller

4.1 Introduksjon til modellbygging

Når vi har samlet inn dataene vi trenger blir neste oppgave å bygge statistiske modeller som representerer dette datasettet. Fordelen med disse modellene er at den gjør datasettet mer forståelig. For eksempel er det mye enklere å si hva gjennomsnittet var i en treningsgruppe enn å ramse opp alle de enkelte observasjonene i datasettet. Forståelig nok ønsker vi å bygge modeller som representerer datasettet godt, og vi vil bruke helt eksplisitte kriterier for å vurdere disse modellene.

Modellene vi skal bygge vil alltid være en variant av ligningen under. Vi bare bytter ut det i parenteser med en spesifikk modell som vi ønsker å bygge.

$$data_i = (modell) + error_i$$

Mange frykter ligninger. Vi også. Men det er ikke så ille når man blir vant til det. Vi kommer til å bruke den samme ligningen til alle våre statistiske tester.

Dessuten hjelper ligninger oss til å huske informasjon bedre.

La oss bryte denne ligningen over:

- **Data** er den faktiske observasjonen (eller målingen) et individ har av den avhengige variabelen, som i vårt tilfelle er % fremgang i 1RM underkroppssøvelser.
- **Modell** er egentlig bare en representasjon av disse dataene.
- **Error** er hvor mye modellen bommer fra den faktiske observasjonen (dvs. data).

Legg merke til den lille i -en som står bak data og error i ligningen. i -en betyr individ og betyr bare at vi kan bruke en modell til å si noe om hva et individ hadde på den avhengige variabelen. Vi kan erstatte i -en med 3 eller 8. Da betyr det bare at vi kan bruke en modell til å si noe om individ 3 og 8. Vi bruker i for å holde det generelt

Modellbygging i praksis

Ligningen over blir mer oppklarende om vi bruker et eksempel:

Forestill deg at du er lege, og at du får inn en pasient som sier hun har feber. Du vet at den normale kroppstemperaturen i populasjonen er $\sim 37^\circ\text{C}$, så det er naturlig å tenke at du kan bruke 37°C som modell.

$$\text{kroppstemperatur}_i = 37 + \text{error}_i$$

Det neste du gjør er å ta en febermåling av pasienten, og du måler kroppstemperaturen til å være 40.

$$40 = 37 + \text{error}$$

Modellen din bommer med 3 grader, fordi $40 - 37 = 3$. Vi kaller slike feil for error.

$$40 = 37 + 3$$

Formelt sett regner vi error for en hvilken som helst modell ved å få error i ligningen alene, ved å reorganisere ligningen.

$$\text{data}_i = \text{modell} + \text{error}_i$$

$$\text{error}_i = \text{data}_i - \text{modell}$$

$$3 = 40 - 37$$

Du har bygget din første modell - Gratulerer!

Du har bygget din første modell. Modellen var riktignok enkel, men du vil snart se at de andre modellene vi skal bygge er veldig like. Den største forskjellen er at modellen ikke blir bygget for å passe perfekt til ett enkelt individ, men til et helt datasett. **Dette er viktig!** I en studie hvor du har mange deltakere med, ønsker vi at modellen skal være en god representasjon av alle disse individene. Med andre ord bør erroren i modell være så liten som mulig

Modeller.

Det er en mer korrekt og presis måte å skrive ligningen under på, og som du ofte ser i artikler og statistikkbøker:

Vi kommer til å benytte denne måten å skrive på fordi det er den dere ser i statistikkbøker og artikler. Tolkningen er akkurat lik.

$$data_i = (modell) + error_i$$

$$Y_i = (b_0) + error_i$$

Her er Y_i den avhengige variabelen for et individ, i . Hvis det kun står b_0 , så betyr det at vi kun estimerer ett enkelt parameter (f.eks. et gjennomsnitt, eller median). I slike tilfeller bruker vi kun ett enkelt parameter til å si noe om hva det enkelte individ hadde i observasjon på den avhengig variabelen, og da predikerer modellen likt for alle individene. Det beste eksempelet vi har til dere er å bruke gjennomsnittet.

Vi kan også bruke en mer kompleks modell, som i ligningen under:

$$Y_i = (b_0 + b_1 X_i) + error$$

X_i er dette individets faktiske måling på variabel, X, som vi ofte kaller for prediktorvariabel. Prediktorvariabelen har også b_1 heftet på seg. Denne forteller oss forholdet mellom prediktorvariabelen (X_i) og den avhengig variabelen (Y_i). b_0 blir her vår prediksjon når X_i er **null** og **0**.

Gjør deg kjent med denne ligningen!

4.2 Visualisering av ulike statistiske modeller


Vi skal nå visualisere ulike modeller for å få en bedre forståelse av hva ulike modeller sier oss. I figurene under ser tre ulike modeller med uinteressante X og Y variabler. Alle har samme b_0 , mens de har forskjellig b_1 .

Husk at b_1 forteller om relasjonen mellom X og Y.

Måten du skal tolke på b_1 på: For **hver enhets økning i X**, dvs. gå fra 1 til 2, 3 til 4, eller 6 til 7, **forventer vi at Y øker med verdien på b_1** . På norsk kalles b_1 for **stigningstallet**. Hvis b_1 er 0, er det ingen relasjon mellom X og Y i vårt datasett.

- I **modell A** ser du at når X øker, øker Y med 0.4 **for hver enhets økning i X**.

- I **modell B** er det ingen relasjon mellom X og Y , så for en enhets økning i X , vil vi forvente at Y forblir den samme.
- I **modell C** er det en negativ relasjon mellom X og Y . Denne modellen sier at for en enhets økning i X , vil vi forvente at Y går ned med 0.4 (siden den er negativ).

Figure 4.1: Modeller med forskjellig b_1

Oppgave

- a. La oss si at vi hatt med et målt et individ sin X til å være 8. Hvis du bruker modell A, hva vil du forvente at denne personen har på Y ?

I figuren ser du tre modeller som har forskjellige b_0 , men samme b_1 . b_0 er verdien på Y når X er 0.

Oppgave.

- b. La oss si at vi hatt med et målt et individ sin X og Y (du kan bytte ut X og Y med hvilken som helst variabel (f.eks. høyde, vekt), hvis du vil). Individet sitt mål på X er 3. Hvis du bruker modell B, hva vil du forvente at denne personen har på Y ?

I figuren under ser du vårt datasett. På Y -aksen har vi plottet % fremgang i RM for deltakerne våre. På X -aksen har vi plottet de to gruppene våre som vi har dummykodet med 0 og 1.

- c. Med utgangspunkt i figuren, hvordan vil du omtrent beskrive en modell som kan passe denne dataen godt?




Figure 4.2: Modeller med forskjellig b_0




Figure 4.3: Vår data

Det er ingen relasjon mellom vår dummykodede variabel og % fremgang 1RM. Modellen vår ser ut til å ha en b_0 på ~ 20 og en b_1 på ~ 20 . Modellen vår ser ut til å ha en b_0 på ~ 10 og en b_1 på ~ 40 . Det er en negativ relasjon mellom vår dummykodede variabel og % fremgang 1RM.

4.3 Modellbygging med ‘Null-Hypothesis Significance Testing (NHST)’

Nå som du har en fått en innføring i hvordan du kan bygge modeller er det på tide at vi begynner å spesifisere hvilke modeller vi skal bygge. Som du sikkert er kjent med jobber forskere innenfor et paradigme som kalles for **Null-Hypothesis Significance Testing (NHST)**. Dette går ut på at forskeren fremstiller to hypoteser:

1. **H₀**: En null-hypotese som sier at det ikke er noen effekt (f.eks. ingen forskjeller mellom grupper, ingen sammenheng mellom variablene)
2. **H₁**: En alternativ/eksperimentell hypotese som sier at det er en effekt (f.eks. det er en forskjell mellom gruppene)

For å teste disse hypotesene må forskeren bygge to modeller: * en modell for null-hypotesen (vi kaller denne for **null-modellen**) * en alternativ-modell som sier det at det er en relasjon eller forskjeller mellom grupper.

Vi regner ut hvor mye error det er i hver av disse modellene for å se hvilke av disse modellene vi gjør det lurt å benytte. Husk at målet er å benytte modeller som er gode og som har lite error. Hvis null-modellen er god nok, så er det ikke noe poeng å bruke den alternative modellen. Men hvis den alternative modellen er mye bedre enn null-modellen, da bør benytte denne.

Statistikken hjelper oss med å ta en beslutning om hvilke av disse modellene vi skal bruke. Forskeren gjennomfører deretter en **statistisk test** som representerer den alternative hypotesen. Utfallet av testen er en **verdi**, for eksempel en *z-verdi*, *t-verdi* eller *f-verdi*, som vi kan bruke til å regne ut sannsynligheten (*p-verdi*) for, gitt at null-hypotesen er sann. Forskjellige tester opererer med forskjellige navn på verdiene sine (sorry, men det er bare slik det er).

4.3.1 Null-modellen (null-hypotesen)

I vår studie ønsker vi å teste om det er forskjeller mellom de to gruppene som har blitt disponert for ulikt treningsopplegg (3 versus 1 sett). Husk at vi har laget en variabel hvor vi har kodet disse som 0 og 1; 0 hvis de trente med ett

4.3. MODELLBYGGING MED ‘NULL-HYPOTHESIS SIGNIFICANCE TESTING (NHST)’21

sett og 1 hvis de trente tre sett. Null-hypotesen er at det ikke er noen forskjeller mellom gruppene. I så fall er gjennomsnittet 1 RM fremgang av alle deltakerne kanskje en god modell. Dette er modellen som representerer null-hypotesen. Med andre ord vår null-modell

$$Y_i = (b_0) + error$$

$$fremgang.1RM = (mean) + error$$

Det er ofte enklere å se denne modellen i tabellform, slik som dere ser under.

Null-modellen (mean)

| |
|-------------|
| individ |
| gruppe |
| rm |
| modell.mean |
| error |
| 1 |
| tre.sett |
| 40.467 |
| 32.162 |
| 8.305 |
| 2 |
| tre.sett |
| 49.072 |
| 32.162 |
| 16.910 |
| 3 |
| tre.sett |
| 47.941 |
| 32.162 |
| 15.779 |
| 4 |
| tre.sett |
| 44.514 |

32.162

12.352

5

tre.sett

52.288

32.162

20.125

6

tre.sett

40.018

32.162

7.855

7

tre.sett

49.484

32.162

17.322

8

tre.sett

29.210

32.162

-2.952

9

tre.sett

40.593

32.162

8.431

10

tre.sett

37.587

32.162

4.3. MODELLBYGGING MED 'NULL-HYPOTHESIS SIGNIFICANCE TESTING (NHST)'23

5.424

11

tre.sett

35.427

32.162

3.264

12

tre.sett

42.494

32.162

10.331

13

ett.sett

17.706

32.162

-14.457

14

ett.sett

17.072

32.162

-15.091

15

ett.sett

18.268

32.162

-13.894

16

ett.sett

25.426

32.162

-6.736

17

ett.sett

32.703

32.162

0.541

18

ett.sett

19.102

32.162

-13.060

19

ett.sett

22.238

32.162

-9.924

20

ett.sett

22.271

32.162

-9.891

21

ett.sett

26.179

32.162

-5.983

22

ett.sett

20.349

32.162

-11.814

23

4.3. MODELLBYGGING MED 'NULL-HYPOTHESIS SIGNIFICANCE TESTING (NHST)' 25

ett.sett

23.528

32.162

-8.635

24

ett.sett

17.960

32.162

-14.203

Opgave.

La oss prøve hvordan denne modellen virker. For individ 1 målte vi en fremgang i 1RM underkropp på **40.467**, men modellen vår sa **32.162**. Så modellen bommet med 8.305, dvs. en error på **8.305**.

$$fremgang.1RM = (mean) + error$$

$$40.467 = 32.162 + 8.305$$

d. Prøv modellen du også: For individ nr. 8, sier modellen at individet hadde en skår på , men denne personen hadde faktisk en skår på . Modellen bommet derfor med .

Vi kan fortsette slik for alle deltakerne vi har hatt med i studien. Husk at vi ikke er interessert i hvor mye bommer for hvert enkelt individ, men for alle indivdene.

e. Hva får du hvis du summerer all erroren for alle indidene? null 0 3 -3.

Tenk over hvorfor du får dette svaret før du leser videre.

Som du så i forrige oppgave blir det feil å summere alle erroren, vi kan løse dette effektivt ved å regne **Sum of Squared Error**. Det vi gjør er å gange error med seg selv ($error^2$) før vi summerer alt dette sammen.

f. Hvis vi regner ut **Sum of Squared Error** for null-modellen for vi:

Tenk over hvorfor du får dette svaret før du leser videre.

Dette tallet er viktig! Dette er null-hypotesen vår! Hvis det ikke er noen forskjell mellom de to treningsgruppene våre er det like greit å bruke denne null-modellen. Men hvis vi finner ut at modellen vår blir bedre (dvs. reduserer

Sum of Squared Error) ved å legge til en prediktorvariabel som består er av gruppevariabelen vår, da bør vi gjøre dette

Bra jobbet!.

Før du går videre er det greit å visualisere hvordan null-hypotesen ser ut rent visuelt. Den prikkete streken i figuren under representerer modellen vår som er mean. Som du ser, så gjør den ingen justeringer for de ulike individene. Erroren er avstanden fra den linjen og opp til hvert datapunkt. Så hvis vi får til å bygge en bedre modell så vil denne avstanden reduseres for alle individene.




Figure 4.4: Modeller med forskjellig b1

4.3.2 Alternativ modell (alternativ hypotese)

I forrige avsnitt sa vi at **null-hypotesen (H0)** representerer en modell som gir samme prediksjon for alle deltakerne som var med i studien uavhengig hvilken treningsgruppe de tilhører. Vi kalte denne for null-modellen. Vi regnet oss også frem til at denne modellen ga oss en Som of Squared error på 3243.784.

Spørsmålet vi skal stille i dette nå er om vi kan redusere error fra denne ved å benytte en mer kompleks modell som benytter (vår dummykodede kategoriske variabel) som prediktorvariabel:

$$Y_i = (b_0 + b_1 X_i) + error$$

Prediktorvariabelen b1 er gruppevariabelen vår som vi dummykodet med tallene 0 og 1. Husker du?

$$Fremgang.1RM_i = b_0 + b_1(Gruppe) + error_i$$

4.3. MODELLBYGGING MED 'NULL-HYPOTHESIS SIGNIFICANCE TESTING (NHST)' 27

For å holde dette på et enkelt og overordnet nivå, gir vi dere de estimerte verdiene for b0 og b1. Målet er å vise dere hvordan denne modellen fungerer.

Senere skal gå gjennom hvordan vi regner ut disse verdiene.

$$Fremgang.1RM_i = 21.90 + (20.52 * Gruppe) + error_i$$

Modellen sier at vår b0 er 21.90. Dette er den forventede verdien på Y (Fremgang.1RM) når prediktorvariabelen er 0. Modellen sier også at b1 er 20.52. Med andre ord den forventede økning i Y for en enhets økning i X, altså stigningstallet. Husk at vi lagde en gruppe-variabel der vi kodet de to gruppene våre med 0 og 1. Så hvis et individ tilhørte gruppe 0, sier modellen at individ som tilhører gruppe 0 har følgende fremgang i 1RM:

$$Fremgang.1RM_i = 21.90 + (20.52 * 0) + error_i$$

Fordi $0 * 20.52 = 0$, blir stående igjen med b0. Modellen predikerer derfor at et individ som tilhører gruppe 0 har 21.90 % fremgang i 1RM.

$$Fremgang.1RM_i = 21.90 + 0 + error_i$$

$$Fremgang.1RM_i = 21.90 + error_i$$

Hvis individet derimot tilhører gruppe 1 predikerer modellen at individet sin skår blir 42.48.

$$Fremgang.1RM_i = 21.90 + (20.52 * 1) + error_i$$

$$Fremgang.1RM_i = 42.48 + error_i$$

Visualisert fremstilt blir modellen vår seendes slik ut:

Opgave.

Tabellen under viser 6 individer som tilhørte treningsgruppe. Du ser deres faktiske fremgang i 1RM kolonnen. La oss bruke det vi har lært til å predikere disse individe sin fremgang. Vi bruker samme modell som over

$$Fremgang.1RM_i = b_0(21.90) + b_1(20.52 * Gruppe) + error_i$$

g. Hva predikerer modellen at individ nummer 3 hadde i skår? (to desimaler)

h. Hva hadde individ nr i skår?




Figure 4.5: Alternativ modell

Table 4.1: Dummy koding

| individ | gruppe | rm | dummykodet |
|---------|----------|--------|------------|
| 1 | tre.sett | 40.467 | 1 |
| 2 | tre.sett | 49.072 | 1 |
| 3 | tre.sett | 47.941 | 1 |
| 4 | tre.sett | 44.514 | 1 |
| 5 | tre.sett | 52.288 | 1 |
| 6 | tre.sett | 40.018 | 1 |

- i. hvor mye error blir det?
- j. i Squared Error blir denne erroren?
- k. nå som du har jobbet med denne modellen, så lurte jeg på om det er noe kjent med disse verdiene i modellen. Gå tilbake til [\[link\]](#) hvis du trenger et hint.
- l. b_0 er (norsk ord) for gruppen som er kodet med 0.
- m. b_1 er (norsk ord) mellom gruppen som er kodet med 0 og gruppen som er kodet med 1.
- n. $b_0 + b_1$ er (norsk ord) for gruppen som er kodet med 1.

I forrige oppgave regnet du ut error for ett enkelt individ. Men vi er interessert i den totale erroren for modellen. Formelen for denne er:

total error in den alternative modellen:

$$SS_R = \sum_{n=1}^N (observert_i - modell_i)^2$$

4.3. MODELLBYGGING MED 'NULL-HYPOTHESIS SIGNIFICANCE TESTING (NHST)' 29

Med andre ord er det kvadraten av den faktiske observasjonen - hva modellen
sa.

- o. Bruk formelen til å regne ut dette. (to desimaler)

Chapter 5

Sammenligne modeller

Nå som vi har bygget de to statistiske modellene - **en null-modell** og **en alternativ modell** - hvor går veien videre? Det vi sitter igjen med er en **error** (les sum of squared error) for null-modellen og en error for alternative modellen. Vår neste oppgave er å finne en måte å **sammenligne disse modellene** på. For å gjøre det helt eksplisitt og tydelig, skal vi nå sammenligne om modellen til høyre er bedre enn modellen til venstre.

Når vi sier at en modell er bedre, så mener vi at den vertikale avstanden fra linjen til datapunktene er kort. Hvis det er stor vertikal avstand fra datapunktet til linjen for mange individer, kan det tyde på at vi har en dårlig modell.

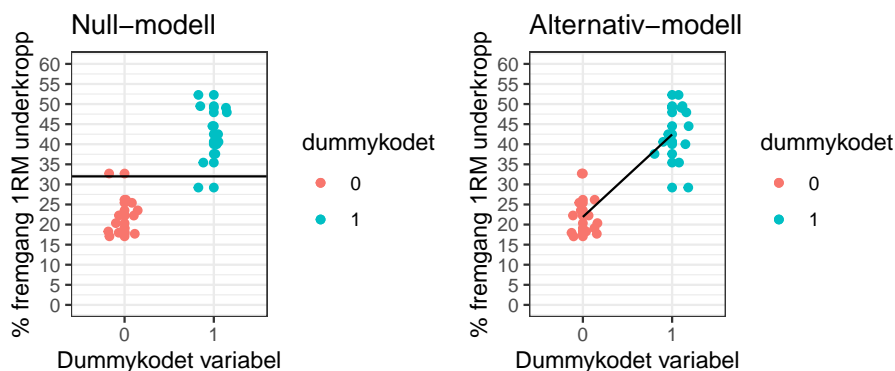


Figure 5.1: Modeller med forskjellig b1

5.1 ANOVA-tabell (variansanalyse)

En måte vi kan sammenligne modeller på er å bruke en ANOVA-tabell, der vi legger inn erroren vi har regnet for de ulike modellene. Dette er en ganske vanlig tabell som dere kommer til å se flere ganger.

ANOVA-tabell

| Modell | SS | df | MS | F | R ² |
|-----------------------------------|----|----|----|---|----------------|
| The model sum of squares (SSM) | | | | | |
| The residual sum of squares (SSR) | | | | | |
| The total sum of squares (SST) | | | | | |

Oppgave

- a. Hva er sum of squared error for null-modellen?

Sett dette inn i total sum of squares (SST)

- b. Hva er sum of squared error for den alternative modellen?

Sett dette inn i residual sum of squares (SSR). Dette er error som er igjen etter at man har brukt den alternative-modellen. Man kaller dette for *residuals*

- c. Hvor mye sum of squared error er redusert ved å bruke den alternative modellen i forhold null-modellen?

Sett dette inn i residual sum of squares (SSM). Dette kalles The model sum of squares (SSM) eller regression i statistiske programmer. Dere regner dette ved å ta (SST-SSM).

Godt jobbet!

Det er ønskelig at SSM er stor fordi det betyr at den alternative modellen vår forklarer mye error. Det kan ofte være lurt å lage figurer for å se dette visuelt. Det er flere måter å gjøre dette på. Vi liker å plote dette i et stolpediagram, slik vi har gjort i figuren under. På denne måten er det enkelt å se om modellen vår (SSM) er en god eller dårlig modell; hvis høyden på stolpen som representerer SSM er høy betyr det at modellen forklarer mye error. I figuren til venstre ser du modellene vi har bygget, og et eksempel på en modell der SSM er høy. Figuren til høyre er ment som et sammenligningsgrunnlag, der vi viser et eksempel på en dårlig modell.

- SST representerer den totale erroren (dvs. erroren vi fikk ved å bruke null-modellen)




Figure 5.2: SS for de ulike modellene

- SSR representerer hvor mye error som er igjen etter at vi brukte den alternative modellen.
 - SSM er hvor mye error som modellen vår klarte å forklare.
- d. Hvis du sammenligner med figuren til venstre (vår modell) med figuren til høyre (som kun er brukt et eksempel), vil du si at vår alternative modell er god?

ja nei.

e. Hva er (SST) - (SSR)?

f. Hva er (SSR) + (SSM)?

Med erroren vi har tilgjengelig kan vi regne noe som heter proporsjonal feilreduksjon (proportional reduction in error (PRE)). Hvis vi multipliserer dette tallet med 100 (* 100) får vi hvor mange % modellen vår har redusert error med, i forhold til null-modellen. Dette er en effektstørrelse som ofte blir rapportert sammen med ANOVA eller regresjonsanalyser. I ANOVA ser du at man rapporterer denne som n^2 , mens man i regresjonsanalyser kaller denne for R^2 . Vi regner ut det på følgende måte:

$$R^2 = \frac{(SS_T - SS_R)}{SS_T} * 100$$

e. Hvilken verdi får du hvis du regner (SSM/ (SST)) * 100?

(uten %-tegnet)

Det er dessverre mange forskjellige navn på denne verdien. Du vil se at folk bruker PRE, n^2 . Vit at de mener det samme.

Ferdig - Bra jobbet!

5.2 Teste (statistisk) om vår alternative modell forklarer mer varians enn null-modellen

En error-reduksjon på 2527.5 (SS_M), eller 78 % ($(R^2) * 100$), kan virke mye. Men et problem med disse størrelsene er at de begge er garantert å øke i takt med antall parametere vi legger til i modellen.

Dere har ikke lært dette enda, men vit at vi kunne bygget en modell der vi inkluderer kjønn, alder, treningsstatus som prediktorvariabler. Da ville dere fått en mer kompleks modell:

$$Y_i = b_0 + b_1(Gruppe_i) + b_2(Kjnn_i) + b_3(Treningsstatus_i) + b_4(Alder_i)$$

Derfor er det mer interessant å regne ut gjennomsnittlig SS_M per parameter vi har lagt til i modellen (i forhold til null-modellen). Dette kalles **Mean Squared Model (MSM)**, eller gjennomsnittlig squared error for den alternative modellen, og regnes på følgende måte:

$$\text{Mean Squared Model } (MS_M) = SS_M/df_M$$

df_m står for antall frihetsgrader som er lagt til i modellen utover null-modellen. Null-modellen har kun ett parameter (b_0), som er mean, mens vår alternative modell har to parametere (b_0 og b_1). Derfor blir $df_M = (2-1) = 1$.

Oppgave

- Regn ut Mean Squared Error (MS_M) og sett det verdien inn i ANOVA-tabellen vår

ANOVA-tabell

| Modell | SS | df | MS | F | R^2 |
|-----------------------------------|----------|----|----|---|-------|
| The model sum of squares (SSM) | 2527.5 | | | | 0.78 |
| The residual sum of squares (SSR) | 716.2875 | | | | |
| The total sum of squares (SST) | 3243.784 | | | | |

5.2. TESTE (STATISTISK) OM VÅR ALTERNATIVE MODELL FORKLARER MER VARIANS ENN NULL-MODELLEN

Det vi ønsker at dere tar med dere fra denne oppgaven er at en høy SS_M eller R^2 er **mer imponerende hvis vi kun har lagt til ett ekstra parameter enn hvis vi hadde lagt til f.eks. 10 parametere**. Enig?

Bra!

Det siste vi skal gjøre er å sammenligne MS_M med MS_R . MS_R er SS_R , den erroren som er igjen etter at vi har brukt den alternative modellen, **delt på antall parametere som i prinsippet kunne vill lagt til i modellen**. I prinsippet står vi fritt til å legge til så mange parametere i modellen som vi ønsker, men antall parametere kan aldri overstige antall deltakere i studien. Men fordi vi allerede har brukt to parametere i den alternative modellen, kan vi kun legge til $(24 - 2) = 22$ parametere.

$$\text{Mean Squared Residual (MSR)} = SS_R/df_R$$

- b. Regn ut Mean Squared Residual (MS_R) og sett det verdien inn i ANOVA-tabellen vår

ANOVA-tabell

| Modell | SS | df | MS | F | R^2 |
|-----------------------------------|----------|----|--------|---|-------|
| The model sum of squares (SSM) | 2527.5 | | 2527.5 | | 0.78 |
| The residual sum of squares (SSR) | 716.2875 | | | | |
| The total sum of squares (SST) | 3243.784 | | | | |

MS_R er gjenstående error per parameter som potensielt kunne blitt lagt til i modellen. Med andre ord er det den gjennomsnittlige erroren som er igjen per parameter som kunne blitt lagt til i modellen. Enig?

Vi er endelig i mål!

Nå har vi gjort alle utregningene, og vi kan bare sammenligne disse to størrelsene (MS_M versus MS_R) med hverandre. Dette kalles en **F-test**.

$$F = \frac{MS_M}{MS_R}$$

- c. Regn ut vår F-verdi og sett den inn i vår ANOVA-tabell

ANOVA-tabell

| Modell | SS | df | MS | F | R ² |
|-----------------------------------|----------|----|----------|---|----------------|
| The model sum of squares (SSM) | 2527.5 | 1 | 2527.5 | | 0.78 |
| The residual sum of squares (SSR) | 716.2875 | 22 | 32.55852 | | |
| The total sum of squares (SST) | 3243.784 | | | | |

Vi kan se at vår F-verdi er 77.63. Denne verdien er høyere enn den kritiske verdien for 0.05 ved $df_M = 1$ og $df_R = 22$. Dette kan du se i figuren under. Vi sier derfor at vår modell er signifikant, hvilket vil si at den har forbedret vår evne til å predikere utfallsvariabelen.

En F-fordeling ser veldig lik ut som en z- og t-fordeling, og fungerer på samme måte: Vi regner ut en F-verdi, og spør om sannsynligheten for å oppnå en slik verdi gitt at null-hypotesen er sann. Null-hypotesen i en F-test er at den alternative modellen ikke forklarer noe varians. Med andre ord at $R^2 = 0$.




Figure 5.3: F-test

Done!

Da er det bare å sette seg tilbake å nyte denne sangen:

Hvis dette ikke var forståelig foreslår jeg følgende tutorials:

- <https://www.youtube.com/watch?v=eSJAjlavPwU>
- <https://www.youtube.com/watch?v=0xWDulRHd9M>
- <https://www.youtube.com/watch?v=iAE4UeoVE9A>
- <https://www.youtube.com/watch?v=OK4Xns4zabs>

5.2. TESTE (STATISTISK) OM VÅR ALTERNATIVE MODELL FORKLARER MER VARIANS ENN NULL-MODELLEN




Figure 5.4: F-testen

Her kan du se output jeg får hvis jeg gjør den statiske analysen i R. Ser verdiene kjent ut?

```
#aov er en forkortelse for analysis of variance (ANOVA)
#dette er funksjon som kommer mer R.
summary(aov(rm ~ dummykodet, dat))
```

```
##              Df Sum Sq Mean Sq F value    Pr(>F)
## dummykodet   1 2527.5   2527.5    77.63 1.15e-08 ***
## Residuals   22   716.3     32.6
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```


Chapter 6

Hvordan finne linjen i modellen?

Nå som vi er kjent med hvordan vi kan bygge og teste statistiske modeller, er det på tide å vise hvordan vi finner regresjonslinjen som vi skal bruke. Mer presist, hvilke verdier skal vi ha for b_0 og b_1 som beskriver denne linjen? Hittil har dere fått disse verdiene av meg, men det vi skal lære nå er hvordan vi kan regne ut disse verdiene for hånd. En viktig sannhet om denne linjen er at regresjonslinjen (les modellen) er plassert slik at den reduserer Sum of Squared Error mest mulig. Med andre ord, verdiene på b_0 og b_1 (som beskriver denne linjen) er slik at det er umulig å redusere error mer. Spørsmålet er hvordan vi finner verdiene på b_0 og b_1 som beskriver denne linjen. En tilnærming kan være å gjette seg fram til hva b_0 og b_1 skal være. Vi kan teste ut ulike verdier for b_0 og b_1 , og evaluere hvor mye sum of Squared Error disse gir. I figuren under har jeg prøvd tre ulike modeller, og regner ut hvor mye sum of squared error disse gir.

Oppgave

a) Hvilken av modellene over gir mest sum of squared error? (SSModel)

$b_0=30$ $b_1=7$ $b_0=25$ $b_1=28$ $b_0=10$ $b_1=30$

Vi kan holde på slik med slik prøving-og-feiling til vi faktisk finner linjen som reduserer error mest. Det er bare å teste nok verdier. **Minste kvadraters metode** garanterer oss å alltid gi oss er svar. Jeg har laget en video til dere som viser vi kan prøve-og-feile til vi kommer frem til en løsning (se denne):

Det er en mer effektiv måte å løse dette problemet på. For å finne **b_1** kan vi bruke følgende formel:




Figure 6.1: Ulike linjer

$$b_1 = \frac{SCP}{SS_x}$$

Her var det et nytt begrep, **SCP**. SCP står for sum of cross-product deviations. Det brukes til å finne relasjonen mellom to variabler, og er grunnlaget for en rekke utregninger i statistikken, så det kan være lurt å lære seg. SCP finner ut av om en person som er over eller under gjennomsnittet på en variabel, også er over eller under gjennomsnittet på den andre variabelen.

$$b_1 = \frac{SCP = \sum_{n=1}^N (x_i - \bar{x})(y_i - \bar{y})}{SS_x}$$

\bar{x} er gjennomsnittet på x-variabelen (gruppe), mens \bar{y} er gjennomsnittet for y-variabelen (1RM). I tabellen under ser du hvordan vi regner dette. Kolonnen CrossProduct er $(x_i - \bar{x})(y_i - \bar{y})$.

$$b_1 = \frac{SCP = 20.52436}{SS_x}$$

Nå som vi har regnet SCP er det bare å regne SS_x (sum of squared error for prediktorvariabelen) er fordi man ønsker å ta høyde for hvor mye prediktorvariabelen avviker fra mean. Jeg har dessverre ikke noen supergod forklaring, og jeg synes heller ikke Field forklarer dette godt. Så jeg bare vet at jeg må gjøre det.

$$b_1 = \frac{SCP = 20.52436}{6}$$

Table 6.1: Utregning av Sum of Cross Product (SCP)

| individ | gruppe | gj.snitt.x | error.x | rm | gj.snitt.y | error.y | CrossProduct |
|---------|--------|------------|---------|----------|------------|-------------|--------------|
| 1 | 1 | 0.5 | 0.5 | 40.46704 | 32.16231 | 8.3047301 | 4.1523651 |
| 2 | 1 | 0.5 | 0.5 | 49.07223 | 32.16231 | 16.9099106 | 8.4549553 |
| 3 | 1 | 0.5 | 0.5 | 47.94131 | 32.16231 | 15.7789994 | 7.8894997 |
| 4 | 1 | 0.5 | 0.5 | 44.51389 | 32.16231 | 12.3515740 | 6.1757870 |
| 5 | 1 | 0.5 | 0.5 | 52.28750 | 32.16231 | 20.1251864 | 10.0625932 |
| 6 | 1 | 0.5 | 0.5 | 40.01750 | 32.16231 | 7.8551872 | 3.9275936 |
| 7 | 1 | 0.5 | 0.5 | 49.48425 | 32.16231 | 17.3219362 | 8.6609681 |
| 8 | 1 | 0.5 | 0.5 | 29.21048 | 32.16231 | -2.9518368 | -1.4759184 |
| 9 | 1 | 0.5 | 0.5 | 40.59293 | 32.16231 | 8.4306117 | 4.2153059 |
| 10 | 1 | 0.5 | 0.5 | 37.58676 | 32.16231 | 5.4244472 | 2.7122236 |
| 11 | 1 | 0.5 | 0.5 | 35.42651 | 32.16231 | 3.2641906 | 1.6320953 |
| 12 | 1 | 0.5 | 0.5 | 42.49354 | 32.16231 | 10.3312265 | 5.1656133 |
| 13 | 0 | 0.5 | -0.5 | 17.70576 | 32.16231 | -14.4565510 | 7.2282755 |
| 14 | 0 | 0.5 | -0.5 | 17.07181 | 32.16231 | -15.0905068 | 7.5452534 |
| 15 | 0 | 0.5 | -0.5 | 18.26811 | 32.16231 | -13.8942055 | 6.9471027 |
| 16 | 0 | 0.5 | -0.5 | 25.42594 | 32.16231 | -6.7363771 | 3.3681886 |
| 17 | 0 | 0.5 | -0.5 | 32.70313 | 32.16231 | 0.5408147 | -0.2704074 |
| 18 | 0 | 0.5 | -0.5 | 19.10226 | 32.16231 | -13.0600552 | 6.5300276 |
| 19 | 0 | 0.5 | -0.5 | 22.23827 | 32.16231 | -9.9240435 | 4.9620217 |
| 20 | 0 | 0.5 | -0.5 | 22.27148 | 32.16231 | -9.8908322 | 4.9454161 |
| 21 | 0 | 0.5 | -0.5 | 26.17889 | 32.16231 | -5.9834246 | 2.9917123 |
| 22 | 0 | 0.5 | -0.5 | 20.34857 | 32.16231 | -11.8137453 | 5.9068726 |
| 23 | 0 | 0.5 | -0.5 | 23.52773 | 32.16231 | -8.6345853 | 4.3172926 |
| 24 | 0 | 0.5 | -0.5 | 17.95966 | 32.16231 | -14.2026514 | 7.1013257 |

$$b_1 = 20.52436$$

Nå gjenstår det bare å finne $\mathbf{b_0}$. Denne er enkel å finne når vi først har funnet $\mathbf{b0}$. Husk at modellen vår er en ligning, så ved enkelt finne $\mathbf{b0}$ ved omorganisere ligningen: trekker vi fra $b_1 X_i$ på hver side av likhetstegnet får vi $\mathbf{b0}$ alene:

$$Y_i = (b_0 + b_1 X_i)$$

$$Y_i - b_1 X_i = (b_0)$$

Men må ligningen med verdier. Og da bruker man gjennomsnittet for Y variabelen og gjennomsnittet for X variabelen.

$$32.16231 - (20.52436 * 0.5) = (21.90013)$$

Chapter 7

T-test - er b_1 signifikant forskjellig fra null?

En F-test tester om vår alternative modell er en bedre modell enn null-modellen, totalsett. Men det kanskje mest interessante spørsmålet er fremdeles er fremdeles delvis ubesvart:

er b_1 i modellen vår, altså vårt stigningstall som representer den forventede endringen i utfallet for en enhets endring i prediktorvariabelen, signifikant forskjellig fra null?

Før du leser videre, forsøk å forestill deg hvordan en modell med en b_1 som er 0 ser ut?

Her er svaret:

- Hvis b_1 er 0, er det ingen relasjon mellom disse prediktorvariabelen (x) og utfallsvariabelen (y).
- Hvis b_1 er $>$ enn 0, er det en positiv relasjon mellom vår prediktorvariabel og utfallsvariabelen.
- Hvis b_1 er $<$ enn 0, er det en negativ relasjon mellom vår prediktorvariabel og utfallsvariabelen.

Husk at b_1 i vårt tilfelle representer forskjellene i gjennomsnitt mellom de to gruppene. Det er med andre ord like gyldig å spørre om det er en relasjon mellom variablene som at det er en forskjell i means mellom to grupper.

Vi kan tydelig se at b_1 er forskjellig fra 0 i vårt utvalg, men husk at denne forskjellen kan skyldes sampling variation som vi kan forvente under null-hypotesen. Vi må derfor teste om de to utvalgene vi har kommer fra samme eller to forskjellige populasjoner (en endring som i så fall har skjedd

44CHAPTER 7. T-TEST - ER B_1 SIGNIFIKANT FORSKJELLIG FRA NULL?

fordi vi har gitt de to utvalgene forskjellig treningsopplegg). Dette kan vi finne ut ved å kjøre en uavhengig t-test.

$$t.test = \frac{(b_1_{\text{observert}} - b_1_{\text{forventet}})}{\text{standard error of } b_1}$$

Vi vet allerede b_1 observert (den observerte forskjellen mellom de to utvalgene) og b_1 forventet (null-hypotesen er at det ikke er noen relasjon mellom disse variablene, så denne blir null. Så vi kan plote inn disse verdiene.

$$t.test = \frac{(20.52 - 0)}{\text{standard error of } b_1}$$

Det som gjenstår er å finne ut hva standard error of b_1 er. Vi har tidligere regnet ut standard error of mean SD/\sqrt{N} , og vi kan gjøre noe lignende for å regne ut standard error of b_1 . Men for å fokusere på det store bildet vil jeg gi dere den estimerte standard error of b_1

Prosedyren for å regne ut standard error of b_1 er ikke vanskelig, men det er en del utregningsledd. Så lenge dere forstår at standard error of b_1 er et mål på hvor mye utvalg vil være forskjellige fra hverandre, så tenker jeg at dere ikke vil øke deres forståelse ved å lære å regne standard error of b_1 , men jeg kan selvfølgelig ta feil.

Jeg anbefaler dere på det sterkeste at der ser denne videoen

Fra mitt output i Jamovi kan jeg lese at standard error of b_1 er **2.33**.

| Independent Samples T-Test | | | | | | | |
|----------------------------|-----------|------|-------|-----------------|---------------|-------------------------|-------|
| | | | | | | 95% Confidence Interval | |
| | Statistic | df | p | Mean difference | SE difference | Lower | Upper |
| 1rm Student's t | 8.81 | 22.0 | <.001 | 20.5 | 2.33 | 15.7 | 25.4 |

Figure 7.1: ny

Så jeg kan bruke dette i utregningen av t.

$$t.test = \frac{(20.52 - 0)}{2.33}$$

$$t.test = \frac{(20.52 - 0)}{\text{standard error of } b_1}$$

$$t.test = 8.806867$$

Vår t-verdi er 8.80. Vi kan tydelig se at denne t-verdier er større enn den kritiske verdien på ~ 2 , så vi kan konkludere at vi har et signifikant funn; de to utvalgene vi har med i studien synes å komme fra forskjellige populasjoner. Vi kan lese denne t-verdien fra output-tabellen fra Jamovi at vår p-verdi er < 0.001 .

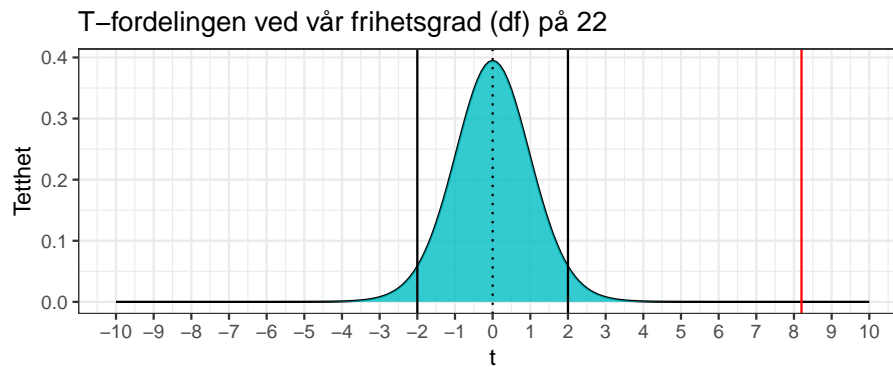


Figure 7.2: t-fordelingen og vår t-verdi

Chapter 8

Skrive en t-test

Det er en ganske standardisert måte å rapporte en statistisk test på. Først skriver du hva du har testet. Husk at du bare har gitt statistikprogrammet noen tall og fått et resultat. Nå må du kommunisere til andre.

'Deltakerne i 1L-3U 3L-1U-gruppen hadde i gjennomsnitt mindre større en lavere % fremgang 1RM, på underkroppsøvelser (M=,SD=), enn som [].

Denne forskjellen, [], CI [], var signifikant, $t([]) = []$, $p = []$, $d=[]$.

Det eneste vi ikke er regnet er d. Dette er cohen's d, og er et mål på effektstørrelse. Du får oppgitt denne i Jamovi.

Chapter 9

Sammenligne flere grupper

Nå har sett om det er forskjeller mellom to grupper på en kontinuerlig, avhengig variabel, men i flere sammenhenger ønsker vi å studere om det er **forskjeller mellom flere grupper**. Kanskje har vi gjort et eksperiment der en gruppe ikke har trent (gruppe 1), en gruppe som har trent middels mye (gruppe 2) og en tredje gruppe som har trent kjempemye (gruppe 3). Vi kan i prinsippet ha så mange grupper vi bare vil.

For å finne ut av dette kan vi bruke en **ANOVA**. Dere er allerede kjent med ANOVA, så jeg kommer ikke til å introdusere dere for noe nytt. Eller, jo, en liten ting, en det kommer jeg tilbake til.

Siden vi har lært å bruke en lineær modell, så slipper vi å lære oss noe nytt når vi nå skal sammenligne flere grupper. Teknikken vi allerede har lært oss kan enkelt brukes til andre formål

Når dere leser dette, vennligst ofre en liten tanke til de stakkarene som må lære seg ANOVA, t-test, ANCOVA osv., som helt forskjellige statistiske tester! Da blir det mange formler å lære seg.

9.1 Datasett

Fordi vi nå skal undersøke om tre grupper er forskjellige, trenger vi et nytt datasett. Datasettet vi skal bruke er hentet fra masteroppgaven til Varpestuensom han leverte i 2020. Tittelen på oppgaven var:

Effekter av 7 uker styrketrening med høyt og moderat volum på muskelstyrke, muskeltykkelse og total-RNA hos unge voksne

Det er en veldig interessant studie der han undersøkte effekten av å trene med moderat og høyt volum på muskelstyrke, muskeltykkelse og total-RNA.

Eksperimentet ble gjennomført som et between-subject design med tre grupper:

- en gruppe som ikke trente styrketrening (*null.sett*)
- en gruppe trente tre sett med styrketrening (*tre.sett*)
- en gruppe som trente seks sett med styrketrening (*seks.sett*)

Vi har ikke tilgang på dette datasettet, men vi simulert datasettet i R. Se tabellen under. Som dere kan lese fra tittelen til oppgaven, har Varpestuen undersøkt effekten av 7 uker styrketrening på **muskelstyrke**, **muskeltykkelse** og **total-RNA** i vastus lateralis hos unge voksne. Det er altså flere avhengige variabler i studien hans, men for å gjøre dette enkelt, skal vi konsentrere oss om **muskeltykkelse**. Vi kan lese i metodekapittelet at han brukte ultralyd for å måle dette og at han rapporterte dette i mm. Men siden han ville se på fremgang regnet han om dette til % fremgang fra første treningsuke.

Her ser dere datasettet som vi har simulert:

Før du går videre er det greit at du gjør deg kjent med datasettet som vi har generert. Studer datasettet og svar på følgende spørsmål:

- a) Hvor mange kolonner er det i tabellen over?
- b) Hvor mange deltakere var med i studien?

9.2 Oppsummere og visualisere dataen

Det er alltid lurt å starte med å visualisere dataen.

Oppgave

- a) Hvem hadde mest fremgang tre.sett seks.sett


9.3 Dummykoding

Vi sa at vi ikke skulle introdusere dere for noe nytt. Vi løy. En ting er forskjellig når vi skal bruke en ANOVA til å sammenligne flere grupper, og det er hvordan vi skal kode variablene. Dere husker kanskje at vi ikke kunne legge tekst inn i de statistiske modellene våre? Derfor bruke vi **dummykoding**. Da

vi brukte dummykoding sist, ga lagde vi en dummyvariabel der vi ga baseline-gruppen verdien 0, mens vi ga treatment-gruppen verdien 1. Dere tror kanskje at det bare er å fortsette denne prosedyren slik at vi gir den siste gruppen verdien 2? Feil. Dummykoding tillater ikke dette. Grunnen er at da at vi antar at det er et lineært forhold mellom disse gruppene, hvilket det

Table 9.1: Simulert datasett (Varpestuen 2020)

| individ | gruppe | vl_tykkelse |
|---------|-----------|-------------|
| 1 | null.sett | 3 |
| 2 | null.sett | 6 |
| 3 | null.sett | 1 |
| 4 | null.sett | 1 |
| 5 | null.sett | -2 |
| 6 | null.sett | -5 |
| 7 | null.sett | 7 |
| 8 | null.sett | 14 |
| 9 | null.sett | 9 |
| 10 | null.sett | -2 |
| 11 | null.sett | 4 |
| 12 | null.sett | 10 |
| 13 | null.sett | 5 |
| 14 | null.sett | 1 |
| 15 | null.sett | 5 |
| 16 | null.sett | 6 |
| 17 | null.sett | 1 |
| 18 | null.sett | 4 |
| 19 | null.sett | 1 |
| 20 | null.sett | 3 |
| 21 | tre.sett | 18 |
| 22 | tre.sett | 12 |
| 23 | tre.sett | 16 |
| 24 | tre.sett | 10 |
| 25 | tre.sett | 9 |
| 26 | tre.sett | 11 |
| 27 | tre.sett | 16 |
| 28 | tre.sett | 14 |
| 29 | tre.sett | 8 |
| 30 | tre.sett | 12 |
| 31 | tre.sett | 8 |
| 32 | tre.sett | 1 |
| 33 | tre.sett | 16 |
| 34 | tre.sett | 16 |
| 35 | tre.sett | 15 |
| 36 | tre.sett | 9 |
| 37 | tre.sett | 14 |
| 38 | tre.sett | 6 |
| 39 | tre.sett | 10 |
| 40 | tre.sett | 11 |
| 41 | seks.sett | 17 |
| 42 | seks.sett | 26 |
| 43 | seks.sett | 25 |
| 44 | seks.sett | 22 |
| 45 | seks.sett | 29 |
| 46 | seks.sett | 17 |
| 47 | seks.sett | 26 |
| 48 | seks.sett | 6 |

Figure 9.1: ****CAPTION THIS FIGURE!!****

kanskje ikke er. Dummykoding sier at vi må løse denne på følgende måte: **VI MÅ LAGE EN DUMMYVARIABEL TIL**. Det vil si at vi har to Dummyvariabler. I tabellen under ser du oppsettet vi skal bruke:

Dummykoding

| Treningsgruppe | Dummy1 | Dummy2 |
|----------------|--------|--------|
| Null sett | 0 | 0 |
| Tre sett | 1 | 0 |
| Seks sett | 0 | 1 |

Oppgave

- Hva har vi kodet null.sett gruppen med på Dummyvariabel 1? 1 0
- Hva har vi kodet null.sett gruppen med på Dummyvariabel 2? 1 0
- Hva har vi kodet tre.sett gruppen med på Dummyvariabel 2? 1 0
- Hva har vi kodet seks.sett gruppen med på Dummyvariabel 2? 0 1
- Hva har vi kodet seks.sett gruppen med på Dummyvariabel 1? 1 0

La oss ta en titt hvordan dette ser ut i tabellen vår:

Oppgave La samme oppsett selv, men husk at dere egentlig ikke trenger å gjøre dette fordi Jamovi gjør dette automatisk for dere, enten dere vil eller ikke.

9.4 ANOVA - er modellen vår bedre enn null-modellen?

Denne gangen starter vi må å teste om modellen vår, som består av de to Dummykodede prediktorvariablene Dummy1 og Dummy2, er en bedre enn null-modellen som sier at vi like greit kan bruke gjennomsnittet for de 60 individene til å predikere en person sin skår. Her har jeg gjort dette for dette i

Table 9.3: Dummykoding

| individ | gruppe | vl_tykkelse | dummy1 | dummy2 |
|---------|-----------|-------------|--------|--------|
| 1 | null.sett | 3 | 0 | 0 |
| 2 | null.sett | 6 | 0 | 0 |
| 3 | null.sett | 1 | 0 | 0 |
| 4 | null.sett | 1 | 0 | 0 |
| 5 | null.sett | -2 | 0 | 0 |
| 6 | null.sett | -5 | 0 | 0 |
| 7 | null.sett | 7 | 0 | 0 |
| 8 | null.sett | 14 | 0 | 0 |
| 9 | null.sett | 9 | 0 | 0 |
| 10 | null.sett | -2 | 0 | 0 |
| 11 | null.sett | 4 | 0 | 0 |
| 12 | null.sett | 10 | 0 | 0 |
| 13 | null.sett | 5 | 0 | 0 |
| 14 | null.sett | 1 | 0 | 0 |
| 15 | null.sett | 5 | 0 | 0 |
| 16 | null.sett | 6 | 0 | 0 |
| 17 | null.sett | 1 | 0 | 0 |
| 18 | null.sett | 4 | 0 | 0 |
| 19 | null.sett | 1 | 0 | 0 |
| 20 | null.sett | 3 | 0 | 0 |
| 21 | tre.sett | 18 | 1 | 0 |
| 22 | tre.sett | 12 | 1 | 0 |
| 23 | tre.sett | 16 | 1 | 0 |
| 24 | tre.sett | 10 | 1 | 0 |
| 25 | tre.sett | 9 | 1 | 0 |
| 26 | tre.sett | 11 | 1 | 0 |
| 27 | tre.sett | 16 | 1 | 0 |
| 28 | tre.sett | 14 | 1 | 0 |
| 29 | tre.sett | 8 | 1 | 0 |
| 30 | tre.sett | 12 | 1 | 0 |
| 31 | tre.sett | 8 | 1 | 0 |
| 32 | tre.sett | 1 | 1 | 0 |
| 33 | tre.sett | 16 | 1 | 0 |
| 34 | tre.sett | 16 | 1 | 0 |
| 35 | tre.sett | 15 | 1 | 0 |
| 36 | tre.sett | 9 | 1 | 0 |
| 37 | tre.sett | 14 | 1 | 0 |
| 38 | tre.sett | 6 | 1 | 0 |
| 39 | tre.sett | 10 | 1 | 0 |
| 40 | tre.sett | 11 | 1 | 0 |
| 41 | seks.sett | 17 | 0 | 1 |
| 42 | seks.sett | 26 | 0 | 1 |
| 43 | seks.sett | 25 | 0 | 1 |
| 44 | seks.sett | 22 | 0 | 1 |
| 45 | seks.sett | 29 | 0 | 1 |
| 46 | seks.sett | 17 | 0 | 1 |
| 47 | seks.sett | 26 | 0 | 1 |
| 48 | seks.sett | 6 | 0 | 1 |

- a) Hva er f-verdien?
- b) Er modellen vår signifikant? Nei Ja
- c) Hvor mye error er det i null-modellen? (hint: her må du legge sammen to verdier)

Gratulerer

Yes! Vår modell er bedre enn null-modellen fordi denne var signifikant. Med andre ord, hvis hadde dyttet en helt random prediktorvariabel i modellen vår, så er det veldig usannsynlig å få en så stor som F-verdi som det vi har fått. Kult, la oss feire! **VENT VENT VENT**. Vi vet jo ikke hvilke grupper som er forskjellige. Det må vi også finne ut.

9.5 Hvilke grupper er forskjellige? (post-hoc testing)

For å finne ut av dette må vi kjøre en en post-hoc prosedyre. Outputen under burde se veldig kjent ut, hvis ikke bør dere virkelig gå tilbake til forelesninger eller lese boken

```
summary(lm(vl_tykkelse ~ dummy1 + dummy2, dat))

##
## Call:
## lm(formula = vl_tykkelse ~ dummy1 + dummy2, data = dat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -13.100  -2.600  -0.350   3.025  10.900
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      3.600      1.104   3.261  0.00188 **
## dummy11          8.000      1.561   5.124  3.7e-06 ***
## dummy21         15.500      1.561   9.928  4.9e-14 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.937 on 57 degrees of freedom
## Multiple R-squared:  0.6337, Adjusted R-squared:  0.6208
## F-statistic: 49.3 on 2 and 57 DF,  p-value: 3.719e-13
```

Det første dere ser er hvilken modell vi har kjørt. Denne sier at vi predikerer vl_tykkelse med de to Dummykodede prediktorvariablene våre. Testen sier at

9.5. HVILKE GRUPPER ER FORSKJELLIGE? (POST-HOC TESTING) 55

vår F-verdi er 49.3, og at vår R^2 er 0.6337. Med andre ord forklarer vår modell forklarer hele 63 % av erroren i dataen. Det er mye! Videre sier den at den estimerer de ulike koeffisientene våre til å være 8 og 15.5. Og at intercepten er 3.600. Alle disse var signifikante ved t-tester. Men hva er egentlig disse verdiene for noe?

Tenk over hva 3.6, 8.0 og 15.5 er for noe før du leser videre.

8.0 og 15.5 er stigningstallene i modellen, mens 3.6 er intercepten i modellen vår. La oss se hvordan disse koeffisientene virker i praksis. La oss si at vi ønsker å predikere en person som trente med tre sett sin skår.

$$\text{fremgang muskeltykkelse} = b_0 + b_1(\text{Dummy}_1 i) + b_2(\text{Dummy}_2 i) + \text{error}_i$$

Vi kan legge inn tallene i modellen vår. Siden personen trente med tre sett, og vi ga denne gruppen 1 på Dummyvariabel 1 og 0 på Dummyvariabel 2, blir vår prediksjon:

$$\text{fremgang muskeltykkelse} = 3.6 + (8.0 * 1) + (15.5 * 0) + \text{error}_i$$

$$\text{fremgang muskeltykkelse} = 3.6 + (8.0 * 1) + (15.5 * 0) + \text{error}_i$$

$$\text{fremgang muskeltykkelse} = 3.6 + 8 + \text{error}_i$$

$$\text{fremgang muskeltykkelse} = 11.6 + \text{error}_i$$

Vi tar et eksempel til. Hva hvis personen trente med seks sett? Denne dummykodet vi med 1 på Dummyvariabel 1 og 0 på Dummyvariabel 2. Derfor blir vår prediksjon:

$$\text{fremgang muskeltykkelse} = 3.6 + (8.0 * 0) + (15.5 * 1) + \text{error}_i$$

$$\text{fremgang muskeltykkelse} = 3.6 + (15.5 * 1) + \text{error}_i$$

$$\text{fremgang muskeltykkelse} = 3.6 + 15.5 + \text{error}_i$$

$$\text{fremgang muskeltykkelse} = 19.1 + \text{error}_i$$

Dette er gjennomsnittet i gruppen som trente med seks sett. Til slutt: hva hvis du tilhørte gruppen som trente null sett?

$$\text{fremgang muskeltykkelse} = 3.6 + (8.0 * 0) + (15.5 * 0) + \text{error}_i$$

$$\text{fremgang muskeltykkelse} = 3.6 + (8.0 * 0) + (15.5 * 0) + \text{error}_i$$

$$\text{fremgang muskeltykkelse} = 3.6 + \text{error}_i$$

Dette er gjennomsnittet i gruppen som trente med null sett. Som dere ser fra outputen over, så var denne også signifikant. I figurene under har jeg forsøkt å vise visuelt hva disse verdiene er for noe. Jeg skulle gjerne fått alt sammen i en figur, men det har jeg ikke klart å få til. Men hvis du ser i figur A, så ser du b_0 , som er gjennomsnittet i null.sett-gruppen. Stigningstallet 8.0 representerer forskjellen mellom null.sett-gruppen og tre.sett-gruppen. Hvis du ser i figur B, så ser du b_0 , som igjen er gjennomsnittet for null.sett-gruppen. Det er her linjen starter. Selve linjen representerer stigningstallet og er forskjellen mellom null.sett-gruppen og tre.sett-gruppen.

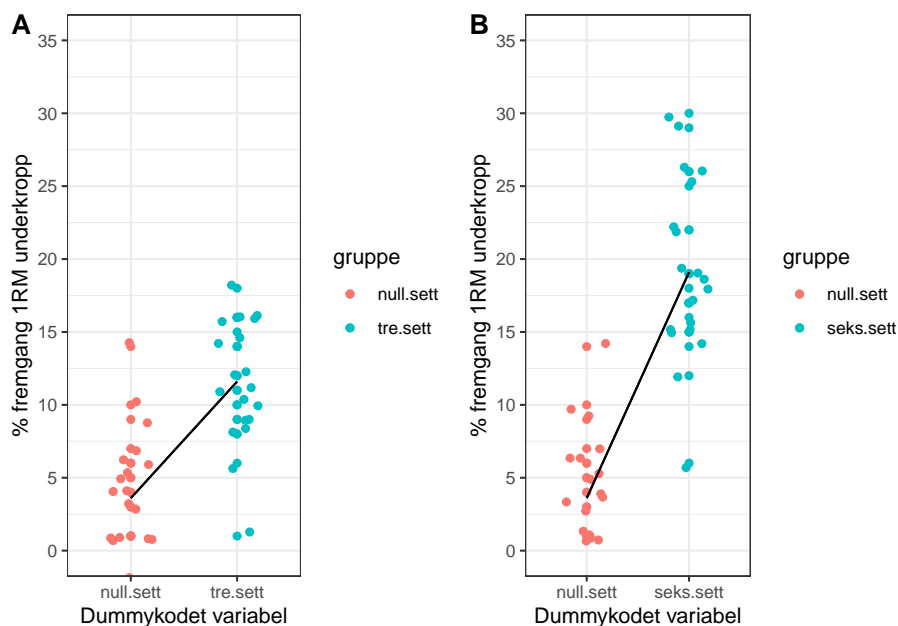


Figure 9.2: **CAPTION THIS FIGURE!!**

Når vi har dummykodet variablene våre sammenligner vi alt med en baseline-gruppe. Men vi skulle gjerne sammenlignet seks.sett gruppen med tre.sett-gruppen, skulle vi ikke? Det får vi ikke gjort med dummykoding. Det er sikkert post-hoc prosedyrer som gjør dette mulig, men ingen av disse står i boken. MEN, det går an å bruke kontrastkoding. Andy Field har en fin video om dette.

<https://www.youtube.com/watch?v=fXDNBeY2qp0>

Chapter 10

Regresjon og korrelasjon

I dette kapitlet skal vi lære hvordan vi kan se om det er en relasjon mellom to kontinuerlige variabler. Tidligere har vi sett om det er relasjoner mellom en avhengig variabel som er kontinuerlig og en variabel som er kategorisk. Men nå skal altså begge være kontinuerlige.

Før vi begynner, la oss repetere hvordan vi kan se om det er en relasjon mellom to variabler. Ta en titt i figuren under:

- I figur A er det en positiv relasjon mellom X og Y. For hver enhets økning i X, så stiger den forventede verdien av Y med 0.4
- I figur B er det ingen relasjon mellom X og Y. Linjen er helt flat
- I figur C er det en negativ relasjon mellom X og Y. For hver enhets økning i X, så faller den forventede verdien av Y med -0.4.

Enig? Dette bør være kjent stoff.

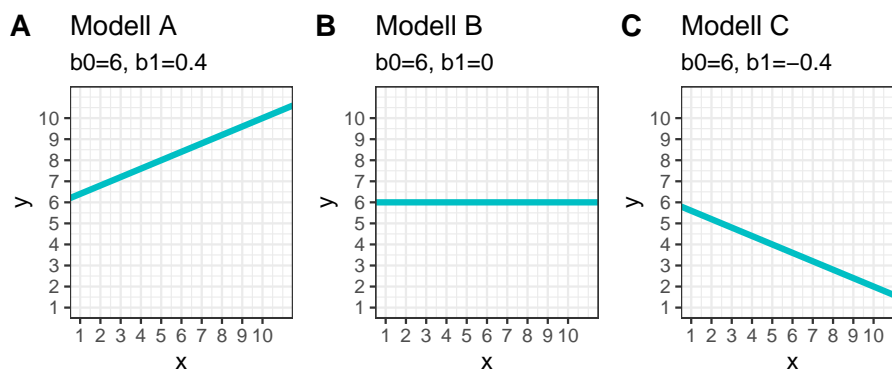


Figure 10.1: Modeller med forskjellig b_1

10.1 Datasett

Før vi begynner med korrelasjon og regresjon, trenger vi et nytt datasett. Datasettet jeg har fisket opp kommer fra *Camus et al. 1992* og inneholder 21 personer sin vo2-maks og tid på 800 meter. Hva tror dere, er det en sammenheng mellom disse variablene?

Her er datasettet:

```
library(tidyverse)
# Vo2-maks
vo2 <- c(52.5, 50, 56.75, 57, 57.5, 58, 60.75, 60.5, 60, 63, 61, 64.5, 64, 65.75, 66.75, 66, 68.25, 68.5, 69.5, 70.5)
# Tidene på 800m
lopprestasjon <- c(159, 147, 153, 160, 143, 132, 130, 135, 137, 128, 121, 125, 130, 137, 141, 136, 129, 134, 138, 142)
# Individene
individ <- seq(length(lopprestasjon))
# Setter dette inn i en dataframe
dat <- data.frame(individ, vo2, lopprestasjon)
```

10.2 Visualisering av dataen

Det første vi bør gjøre er å visualisere dataen for å se om vi har uteliggere, og for å få et inntrykk av dataen. For data der begge variablene er kontinuerlige er det fint å bruke et **scatterplot**. Dette viser hvert individ sin observasjon på X og Y variabelen.

```
ggplot(dat, aes(vo2, lopprestasjon)) +
  # legger på punkter (de stort prikkene)
  geom_point() +
  labs(x="Vo2.maks", y="800meter løp") +
  theme_bw()
```

10.3 Pearson's korrelasjonskoeffisient (r)

For å finne ut om det er en relasjon mellom to variabler, kan vi bruke Pearson's korrelasjonskoeffisient (r). Det er flere måter å regne ut r på, men jeg kommer til å bruke formelen som står i boken deres:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{(N - 1)sd_x sd_y}$$

Table 10.1: Vo2maks og 800meter tid for 21 personer

| individ | vo2 | loppprestasjon |
|---------|-------|----------------|
| 1 | 52.50 | 159 |
| 2 | 50.00 | 147 |
| 3 | 56.75 | 153 |
| 4 | 57.00 | 160 |
| 5 | 57.50 | 143 |
| 6 | 58.00 | 132 |
| 7 | 60.75 | 130 |
| 8 | 60.50 | 135 |
| 9 | 60.00 | 137 |
| 10 | 63.00 | 128 |
| 11 | 61.00 | 121 |
| 12 | 64.50 | 125 |
| 13 | 64.00 | 130 |
| 14 | 65.75 | 137 |
| 15 | 66.75 | 141 |
| 16 | 66.00 | 136 |
| 17 | 68.25 | 122 |
| 18 | 68.00 | 117 |
| 19 | 70.50 | 119 |
| 20 | 73.25 | 121 |
| 21 | 74.00 | 116 |




Figure 10.2: løpsprestasjon

Vi begynner med det som står i telleren $(x_i - \bar{x})(y_i - \bar{y})$. Dette kalles **cross-product deviations**. Det vi er interessert i å finne ut er om en person sin skår på en variabel er over eller under gjennomsnittet på denne variabelen.

Det er dette $(x_i - \bar{x})$ forteller oss. Men samtidig ønsker vi å se om denne personen er over eller under gjennomsnittet på den andre variabelen $(y_i - \bar{y})$. For å finne ut av denne multipliserer vi de to, eller vi regner ut kryssproduktet.

- Hvis det er en positiv relasjon mellom to variabler skal en person sin skår på x-variabelen være høyere enn gjennomsnittet på x-variabelen og samtidig være høyere enn gjennomsnittet på y-variabelen
- Hvis det er en negativ relasjon mellom to variabler skal en person sin skår på x-variabelen være høyere enn gjennomsnittet på x-variabelen og samtidig være lavere enn gjennomsnittet på y-variabelen

Det er enklere å se dette visuelt. I figuren under har jeg lagt på linjer som viser gjennomsnittet. Studer figuren **nøye**. Studer hvordan individene er plassert i forhold til linjene.

Videre forteller formelen at vi skal summere all cross-production deviations, så vi gjøre dette:




Figure 10.3: **CAPTION THIS FIGURE!!**

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{(N-1)sd_x sd_y} = \frac{-1292.19}{(N-1)sd_x sd_y}$$

Deretter sier formelen at vi skal dele antall N-1, multiplisert med standardavviket for x og standardavviket for y. Grunnen til at vi gjør dette er for å få en standardisert relasjon som vi kan sammenligne på tvers av studier.

Legg merke til at vi også må multiplisere de to standardavvikene med hverandre før vi deler.

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{(N-1)sd_x sd_y} = \frac{-1292.19}{(20)1664.213} = -0.7764574$$

Jeg kan bekrefte at denne korrelasjonen stemmer.

```
r <- cor.test(dat$vo2, dat$loppsprestasjon, method="pearson")
r
```

```
##
## Pearson's product-moment correlation
```

```
##
## data:  dat$vo2 and dat$loppsprestasjon
## t = -5.3708, df = 19, p-value = 3.497e-05
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.9048506 -0.5185974
## sample estimates:
##          cor
## -0.7764574
```

Vi kan rapportere dere på følgende måte:

Det var en signifikant relasjon negativ relasjon mellom vo2maks og tid på 800 meter , $r = -0.77$, 95% CI $[-0.90, .52]$, $p = < .001$

En ting som er viktig å vite er at r kun kan variere mellom -1 og 1, aldri mer. Så en r på -0.77 er en stor effekt.

Spill dette spill til dere skjønner korrelasjon: <http://guessthecorrelation.com/>

10.4 Regresjon

Vi kan også gjøre en regresjonsanalyse på samme datasett. Korrelasjon spør om det er en sammenheng eller en relasjon mellom to variabler, mens en regresjon spør om vi kan predikere noe. De to teknikkene er veldig relatert til hverandre. Alt vi har gjort i dette faget er egentlig regresjon, så det er ingenting nytt jeg kommer med nå. Vi skal regresjonsmodell for å spørre om vi kan predikere en person sin løpstid på 800meter basert på deres vo2.maks. Vi har derfor to kontinuerlige variabler som vi kan sette opp med følgende ligning:


$$lopstid = b_0 + b_1(vo2maks_i) + error$$

For å undersøke om vi kan bruke vo2maks til å predikere tid på 800meter, må vi bygge to modeller: - **NULL-modellen** (null-hypotesen som sier at vi kun trenger gjennomsnittet til å predikere tid på 800m) - **Alternative modellen**(modellen vår som sier at kan bruke vo2maks til å predikere tid på 800m)

Disse modellene kan du se i figuren under. Figur A er null-modellen og figure B er den alternative modellen.

```
## `geom_smooth()` using formula 'y ~ x'
```

For å sammenligne disse modellene bruker vi nøyaktig samme prosedyre som har gjort tidligere. Gå tilbake til de andre kapitlene i boken om du ikke husker dette. Jeg kjører derfor bare modellen i R for dere.

Figure 10.4: ****CAPTION THIS FIGURE!!****

```
# lm står for linear model
alternativ_modell <- lm(lopsprestasjon ~ vo2, dat)
summary(alternativ_modell)
```

```
##
## Call:
## lm(formula = lopsprestasjon ~ vo2, data = dat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -15.603  -5.960  -1.766   7.459  16.948
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 234.9559    18.9327  12.410 1.47e-10 ***
## vo2         -1.6123     0.3002  -5.371 3.50e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 8.499 on 19 degrees of freedom
## Multiple R-squared:  0.6029, Adjusted R-squared:  0.582
## F-statistic: 28.85 on 1 and 19 DF, p-value: 3.497e-05
```

10.5 Rapportering av regresjon

Vi fant at vo2.maks predikerte løpstid på 800m, $b = -.161$, $t(19) = -5.37$, $p < .001$. vo2 maks forklarte også en signifikant andel av variansen i løpsprestasjon, $R^2 = .60$, $F(1, 19) = 28.85$, $p < .001$.

Chapter 11

VEDLEGG

11.1 Datasett

- Hvor mange kolonner er det i tabellen over? svar = 3
- Hvor mange deltakere var med i studien? svar = 24
- Hvilke to verdier har variabelen gruppe? svar = ‘ett.sett’ og ‘tre.sett’
- Hvilken gruppe hadde mest fremgang? svar = tre.sett
- Stolpediagram er designet for (svar = “kategorisk”) data.
- Høyden på stolpen representerer (svar = gjennomsnittet), hvilket vil si at det også må ligge noen observasjoner over og under stolpen.
- Et stolpediagram viser ikke (svar=“fordelingen av observasjonene”), og dette er problematisk ved (svar = “små”)) utvalg
- Forfatterne av artikkelen anbefaler mer bruk av (svar = “scatterplot”) for kontinuerlige variabler.
- Er standard error og standardavvik det samme? svar = “nei”)

11.2 Modellbygging

- La oss si at vi hatt med et målt et individ sin \mathbf{X} til å være 8. Hvis du bruker modell A, hva vil du forvente at denne personen har på Y ? svar = 9.2
- La oss si at vi hatt med et målt et individ sin \mathbf{X} og \mathbf{Y} (du kan bytte ut X og Y med hvilken som helst variabel (f.eks. høyde, vekt), hvis du vil). Individet sitt mål på X er 3. Hvis du bruker modell B, hva vil du forvente at denne personen har på Y ? svar = 4.2
- Med utgangspunkt i figuren, hvordan vil du omtrent beskrive en modell som kan passe denne dataen godt? svar = “Modellen vår ser ut til å ha

en b0 på ~ 20 og en b1 på ~ 20 "

- d. Prøv modellen du også: For individ nr. 8, sier modellen at individet hadde en skår på (svar = 32.162"), men denne personen hadde faktisk en skår på svar = 29.210. Modellen bommet derfor med (svar = "-2.952")'.
- e. Hvis vi regner ut **Sum of Squared Error** for null-modellen får vi? svar = 3243.784
- f. Hva predikerer modellen at individ nummer 3 hadde i skår? (to desimaler) svar = 42.42
- g. Hva hadde individ nr 3 i skår? svar = 47.941
- h. hvor mye error blir det? svar = 5.521
- i. i Squared Error blir denne erroren? svar = 30.48144
- j. nå som du har jobbet med denne modellen, så lurer jeg på om det er noe kjent med disse verdiene i modellen. Svar = dette er mean for 0 gruppen og forskjellene mellom gruppene er b1
- k. b0 er (svar=gjennomsnittet) (norskt ord) for gruppen som er kodet med 0.
- l. b1 er (svar=forskjellen) (norsk ord) mellom gruppen som er kodet med 0 og gruppen som er kodet med 1.
- m. b0 + b1 er (svar=gjennomsnittet) (norsk ord) for gruppen som er kodet med 1.

11.3 Sammenlignende modeller

- a. Hva er sum of squared error for null-modellen? svar = 3243.784
- b. Hva er sum of squared error for den alternative modellen? svar = 716.2875
- c. Hvor mye sum of squared error er redusert ved å bruke den alternative modellen i forhold null-modellen? svar = 2527.5
- d. Hvis du sammenligner med figuren til venstre (vår modell) med figuren til høyre (som kun er brukt et eksempel), vil du si at vår alternative modell er god? svar = ja
- e. Hva er (SST) - (SSR)? svar = 2527.5
- f. Hva er (SSR) + (SSM)? svar = 3243.784

Bibliography

- Rønnestad, B., Egeland, W., Kvamme, N., Refsnes, P., Kadi, F., and Raastad, T. (2007). Dissimilar effects of one- and three-set strength training on strength and muscle mass gains in upper and lower body in untrained subjects. *The Journal of Strength and Conditioning Research*, 21:157–63.
- Weissgerber, T. L., Milic, N. M., Winham, S. J., and Garovic, V. D. (2015). Beyond Bar and Line Graphs: Time for a New Data Presentation Paradigm. *PLOS Biology*, 13(4):1–10. Publisher: Public Library of Science.